UNIVERSIDADE FEDERAL DE SERGIPE
DEPARTAMENTO DE COMPUTAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

ATIVIDADE 1
Curadoria de Datasets e Inferência Básica com LLMs

- **Disciplina:** PROCC0111 - TÓPICOS AVANÇADOS EM ENGENHARIA DE SOFTWARE E SISTEMAS DE INFORMAÇÃO I
- **Professor:** GLAUCO DE FIGUEIREDO CARNEIRO
- **Aluno:** 202611011432 - MARCELO MOREIRA WEST

São Cristóvão-SE — 09/04/2026

1 Atividade 1: Curadoria de Datasets e Inferência Básica com LLMs

2 Objetivo

Este trabalho tem como objetivo principal estabelecer um protocolo de curadoria de dados para a avaliação de Modelos de Linguagem de Grande Escala (LLMS), integrando conjuntos de informações com estruturas complementares. A metodologia fundamenta-se na análise de dois datasets do domínio médico: o primeiro, composto por questões abertas, visa mensurar a capacidade de síntese e geração de texto livre; o segundo, baseado em itens de múltipla escolha, foca na validação da precisão técnica e no raciocínio dedutivo especializado sob condições de resposta estruturada.

Para além da organização dos dados, a investigação propõe uma etapa de imersão analítica voltada à inferência básica, servindo como uma fase exploratória essencial para compreender o comportamento dos modelos em domínios de conhecimento específicos. Este contato inicial com os processos inferenciais permite identificar as nuances da arquitetura dos LLMs e os desafios técnicos associados ao processamento de linguagem natural, fornecendo a base empírica necessária para o desenvolvimento de protocolos de avaliação mais complexos e para a otimização de sistemas de suporte à decisão. A Figura 7 apresenta as Etapas da Execução da Atividade 1.

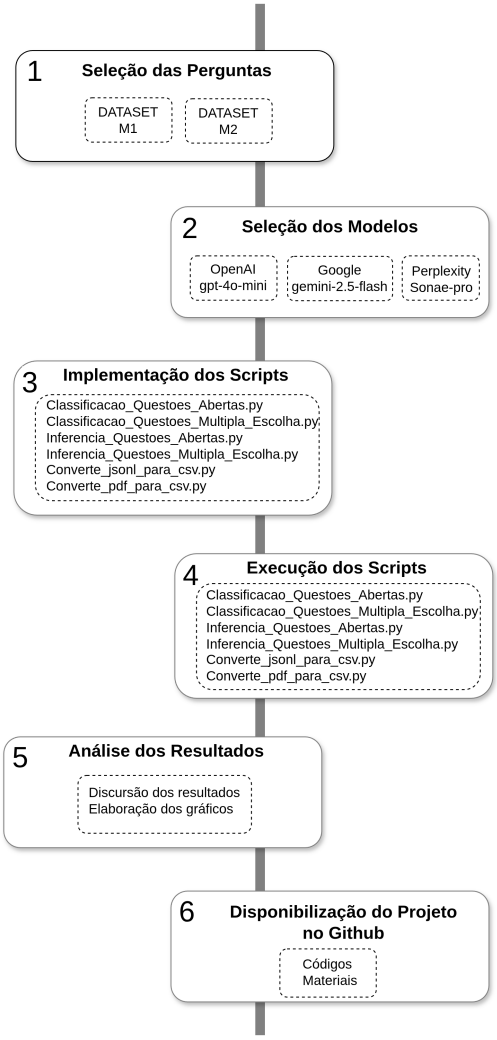

Figure 1: Etapas da Execução da Atividade 1

3 Domínio Médico

A utilização de modelos de linguagem de grande escala no domínio médico justifica-se pela sua capacidade de processar e sintetizar vastos volumes de dados clínicos não estruturados, proporcionando uma avaliação padronizada e escalável da competência profissional (Kung et al., 2023), (Reading Turchioe et al., 2022).

Ao contrário das métricas de avaliação tradicionais, que podem ser limitadas pela subjetividade humana ou pela latência no processamento, os LLMs permitem a realização de benchmarks rigorosos contra padrões-ouro, como o USMLE, demonstrando uma acurácia que muitas vezes atinge o limiar de aprovação exigido de médicos especialistas (Kassab et al., 2023), (Kung et al., 2023).

Além disso, a aplicação de modelos especializados, como a abordagem desta atividade, não apenas pode otimizar o fluxo de trabalho hospitalar através da automação de classificações diagnósticas a partir de laudos textuais, mas também pode estabelecer uma infraestrutura robusta para a educação médica assistida por IA e para o desenvolvimento de sistemas de suporte à decisão de alta precisão (Pedrosa et al., 2021), (Vishwanath et al., 2025), (Wang et al., 2025).

4 Datasets, Códigos e Modelos de Linguagem

4.1 Datasets

Foram utilizados 2 Datasets da Área Médica, cada Dataset de um repositório distinto.

Dataset M1 - Questões Abertas: 135 a 151 - Itaymanes K-QA: O Dataset M1 (K-QA) é um recurso especializado para tarefas de Perguntas e Respostas (QA) no domínio médico, focado em fornecer respostas fundamentadas em evidências clínicas de alta qualidade. Ele foi desenvolvido a partir de diretrizes de prática clínica e fontes médicas confiáveis, visando mitigar alucinações em modelos de linguagem. O diferencial deste conjunto de dados é o foco em informações acionáveis e tecnicamente precisas, sendo frequentemente utilizado para avaliar a capacidade de LLMs em lidar com terminologia médica complexa e raciocínio clínico em cenários onde a precisão é crítica (Manes et al., 2024)

Este dataset é estruturado para suportar tarefas de recuperação de informação e geração de texto, contendo pares de perguntas e respostas que refletem dúvidas reais de profissionais de saúde e estudantes de medicina. Ele serve como um importante benchmark para modelos que buscam especialização em domínios técnicos, permitindo testar se o modelo consegue não apenas responder corretamente, mas também alinhar sua resposta aos protocolos médicos estabelecidos (Manes et al., 2024).

Na preparação do Dataset M1 para a execução da atividade, o mesmo foi convertido do formato original .JSONL para o formato .CSV através do script **Converte_jsonl_para_csv.py**

Clique aqui para visualizar o Dataset M1 Original:

Dataset M2 - Múltipla Escolha com Gabarito: 217 a 243 - USMLE: O Dataset M2 (USMLE - United States Medical Licensing Examination) diz respeito ao exame de licenciamento médico, que consiste em três etapas, sendo este um requisito para os profissionais da medicina que pretendem atuar nos Estados Unidos. A avaliação verifica a habilidade de um médico em aplicar conhecimentos, conceitos e princípios, além de evidenciar competências focadas no paciente, as quais são relevantes tanto na saúde quanto na doença e formam a base para um atendimento seguro e eficaz. No âmbito da Inteligência Artificial e do Processamento de Linguagem Natural, pesquisadores empregam as questões desse exame para desenvolver datasets de referência (benchmarks), como o MedQA, que desafiam os modelos a solucionar problemas de raciocínio clínico de elevada complexidade (Kassab et al., 2023).

Os datasets derivados do USMLE são reconhecidos como a referência máxima para a avaliação da competência médica em Modelos de Linguagem de Grande Escala (LLMs), uma vez que as questões requerem não somente a memorização de informações, mas também a integração de dados diagnósticos, a compreensão

da fisiopatologia e a habilidade de tomada de decisão clínica. Devido à sua natureza exigente e à constante atualização, a aplicação de seus dados para o treinamento e a avaliação de modelos possibilita a medição precisa do avanço da inteligência artificial em direção a habilidades profissionais no campo da saúde, funcionando como um indicador de desempenho em contextos nos quais a precisão e o raciocínio clínico se mostram fundamentais (Kassab et al., 2023).

Na preparação do Dataset M2 para a execução da atividade, o mesmo foi convertido do formato original .PDF para o formato .CSV através do script **Converte_pdf_para**$_{c}sv.py$

Clique aqui para visualizar o Dataset M2 Original:

4.2 Códigos

Foram desenvolvidos 4 scripts em Python para alcançar o objetivo desta atividade.

4.2.1 Classificação:

Os scripts "Classificacao_Questoes_Abertas.py" e "Classificacao_Questoes_Multipla_Escolha.py" classificaram as questões em 4 categorias:

- **Triagem: Questões que qualquer leigo ou sistema básico resolve.**
- **Generalista: Exige conhecimento técnico base, mas não especialização profunda.**
- **Especialista: Requer conhecimento técnico avançado, protocolos específicos ou histórico de casos complexos.**
- **Expert: Casos sem precedentes claros ou que exigem tempo maior de experiência e pesquisa.**

4.2.2 Inferência:

Foram utilizados 3 Modelos de Linguagem de Grande Escala (LLMS), cada modelo de um provedor distinto para a execução da inferência.

OpenAI: gpt-4o-mini: O GPT-4o-mini é um modelo de linguagem de pequeno porte da OpenAI, projetado para oferecer um equilíbrio otimizado entre alto desempenho e eficiência de custo em tarefas de inteligência artificial. Lançado como um sucessor mais capaz e econômico ao GPT-3.5 Turbo, ele suporta multimodalidade nativa (processando texto, áudio, imagens e vídeo) e possui uma janela de contexto de 128 mil tokens. Sua arquitetura é especialmente eficaz para aplicações que exigem baixa latência, como assistentes em tempo real e automação de fluxos de trabalho, superando modelos de sua categoria em benchmarks de raciocínio acadêmico e codificação, ao mesmo tempo em que se mantém acessível para desenvolvedores que operam em larga escala ou em ambientes com recursos mais limitados.

Google: gemini-2.5-flash: O Gemini 2.5 Flash é um modelo de linguagem da Google, desenvolvido para oferecer velocidade extrema e eficiência sem comprometer a capacidade de raciocínio complexo. Como um modelo de porte médio otimizado para multimodalidade nativa, ele se destaca pelo processamento de grandes volumes de dados (long-context) com baixa latência, sendo ideal para aplicações que exigem respostas rápidas em texto, código, imagens e vídeo. Sua arquitetura foi refinada para ser altamente eficaz em tarefas de sumarização, extração de dados e conversação fluida, posicionando-se como uma ferramenta robusta para desenvolvedores que buscam escalar soluções de IA com um custo-benefício superior, especialmente em fluxos de trabalho que demandam alta frequência de chamadas de API e processamento em tempo real.

Perplexity: sonar-pro: O Sonar Pro é um modelo de linguagem avançado desenvolvido pela Perplexity, focado em transformar a experiência de busca convencional em uma interface de resposta direta, precisa

e atualizada em tempo real. Diferente de modelos estáticos, ele é integrado a um motor de busca que realiza a varredura ativa da web para fundamentar cada resposta com fontes citadas, mitigando significativamente o risco de alucinações. O modelo é otimizado para lidar com consultas complexas que exigem a síntese de múltiplas informações, oferecendo um equilíbrio entre profundidade analítica e agilidade, o que o torna uma ferramenta poderosa para pesquisa acadêmica, análise de mercado e verificação de fatos em ambientes onde a validade da informação é a prioridade máxima.

Para efetuar as inferências foram utilizados os scripts "Inferencia_Questoes_Abertas.py" e "Inferencia_Questoes_Multipla_Escolha.py".

Nesta etapa, foram submetidas 17 questões abertas do Dataset M1 (135 a 151 - Itaymanes K-QA) e submetidas 27 questões de Múltipla Escolha do Dataset M2 (217 a 243 - USMLE), sendo gerados 4 arquivos: "resultadosM1_modelos.csv", "resultadosM2_modelos.csv", "metricasM1_modelos.csv" e "metricasM2_modelos.csv"

Os dois primerios arquivos registraram: Identificador, Pergunta, Resposta_Correta, Resposta_GPT, Resposta_Gemini e Resposta_Perplexity e os dois últimos arquivos registraram os valores das métricas accuracy e f1_macro alcançadas.

5 Resultados

A Tabela 1 apresenta as questões do Dataset M1 classificadas pelas categorias das perguntas, conforme os modelos de linguagem: OpenAI: gpt-4o-mini, Google: gemini-2.5-flash e Perplexity: sonar-pro.

5.1 Classificação das questões do Dataset M1

Table 1: Classification of (Questions 135 to 151) from Dataset M1

ID	Question	gpt-4o-mini	gemini-2.5-flash	sonar-pro
1	No I have not is vomiting a Covid symptom?	Screening	Screening	Screening
2	No what is vestibular nueritis?	Generalist	Generalist	Generalist
3	Oh one quick question is there anything that can be prescribed to treat hemorrhoids?	Generalist	Generalist	Screening
4	Ok I will do the blood pressure checks, how often?	Screening	Generalist	Generalist
5	Ok, is it odd the sore throat would have gone away within 24 hours though after taking the antibiotic?	Generalist	Generalist	Screening
6	Okay, what other signs could indicate pink eye if it were to manifest?	Screening	Generalist	Screening
7	On the losartan can I take two pills at once or at separate times?	Generalist	Generalist	Screening
8	One last question, can viral infections cause purulence to form in the eye?	Generalist	Generalist	Screening
9	Or could bactrim potentially cause a yeast infection?	Generalist	Generalist	Screening
10	Question- the loss of hearing is consistent with outer ear infection and not inner?	Specialist	Generalist	Generalist
11	Should I take a lower dose of my sertraline while taking the zofran?	Specialist	Generalist	Generalist
12	Since I took Fioricet about an hour ago, can I take ibuprofen?	Generalist	Generalist	Screening
13	So if I have prostatitis what would I be prescribed?	Generalist	Generalist	Screening
14	So if the diarrhea started last night, Im assuming I would be no longer contagious by tomorrow night?	Generalist	Generalist	Screening
15	So prednisone is a cortisone type medication?	Generalist	Generalist	Screening
16	So ringworm doesnt itch?	Screening	Generalist	Screening
17	So the Flonase is an anti inflammatory?	Generalist	Screening	Screening

5.2 Classificação das questões do Dataset M2

A Tabela 2 apresenta as questões do Dataset M2 classificadas pelas categorias das perguntas, conforme os modelos de linguagem: OpenAI: gpt-4o-mini, Google: gemini-2.5-flash e Perplexity: sonar-pro.

Table 2: Classification of (Questions 217 to 243) from Dataset M2

ID	Abbreviated Question	gpt-4o-mini	gemini-2.5-flash	sonar-pro
Question 18.1	PTSD claim after motor vehicle collision; best way to confirm diagnosis in a legal context.	Specialist	Specialist	Specialist
Question 19.1	Progressive dyspnea, childhood illness, diastolic rumble, atrial fibrillation; most helpful diagnostic study.	Specialist	Generalist	Specialist
Question 20.1	Child with brain injury, fever, oliguria, elevated creatinine, low urine sodium; likely cause of kidney injury.	Specialist	Specialist	Specialist
Question 22.1	Sudden leg collapse with laughter, excessive daytime sleepiness, refreshing naps; most likely diagnosis.	Specialist	Generalist	Specialist
Question 23.1	Mesothelioma case-control study; rationale for selecting controls with chest x-rays.	Specialist	Generalist	Specialist
Question 24.1	Elderly man with metastatic prostate cancer and vertebral lesions; response to daughter's concern.	Specialist	ERRO	Specialist
Question 25.1	Fever, abdominal pain, bloody diarrhea; most likely infectious organism.	Specialist	Generalist	Specialist
Question 26.1	Campylobacter diarrhea followed by knee arthritis; best diagnostic study.	Specialist	Generalist	Specialist
Question 27.1	Black nipple discharge with prior benign imaging; next diagnostic step.	Specialist	Specialist	Specialist
Question 28.1	Drug X trial with cancer deaths; calculate relative risk.	Specialist	Generalist	Specialist
Question 29.1	Menstruating woman with fever, rash, shock; diagnosis and cause.	Specialist	Specialist	Specialist
Question 30.1	Elderly man with shoulder stiffness, fatigue, high ESR; main risk factor.	Specialist	Generalist	Specialist
Question 31.1	Child with seizure treated with diazepam followed by respiratory failure; cause.	Specialist	Specialist	Specialist
Question 32.1	Hodgkin lymphoma patient with anemia and dark stools after chemotherapy; explanation.	Specialist	Specialist	Specialist
Question 33.1	Late-preterm newborn with tachypnea and fissural fluid; most likely diagnosis.	Specialist	Generalist	Specialist
Question 35.1	Young woman with bloody mucus and family history of colon cancer; best study.	Specialist	Specialist	Specialist
Question 36.1	Teen with gait disturbance, papilledema, behavioral changes; working diagnosis.	Specialist	Specialist	Specialist
Question 37.1	Elderly man with fever, RUQ pain, bile duct dilation; diagnosis.	Specialist	Specialist	Specialist
Question 38.1	Elderly woman with worsening tremor after fluoxetine; cause.	Specialist	Generalist	Specialist
Question 39.1	Dyspnea, atrial fibrillation, pleural effusion; next step.	Specialist	Generalist	Specialist
Question 40.1	Post-AAA repair patient with abdominal pain and fever; diagnostic study.	Specialist	Generalist	Specialist
Question 42.1	Pregnant woman with dyspnea, hemoptysis, diastolic murmur; cause.	Specialist	Specialist	Specialist
Question 43.1	Diabetic patient with vomiting and early satiety; explanation.	Specialist	Generalist	Specialist
Question 44.1	Elderly woman with fatigue and diffuse pain, normal labs; next step.	Specialist	Generalist	Specialist
Question 45.1	Severe pneumonia with hypoxemia and infiltrates; underlying cause.	Specialist	Specialist	Specialist

ID	Abbreviated Question	gpt-4o-mini	gemini-2.5-flash	sonar-pro
Question 46.1	**Physician suspected of alcohol use on duty; next action.**	**Specialist**	**Specialist**	**Specialist**
Question 47.1	**Elderly man with groin pain and hip limitation; imaging study.**	**Specialist**	**Generalist**	**Specialist**

A Tabela 3 apresenta a concordância e distribuição percentual das classificações, conforme os modelos de linguagem: OpenAI: gpt-4o-mini, Google: gemini-2.5-flash e Perplexity: sonar-pro.

Table 3: Agreement and percentage distribution of classifications (Questions 135 to 151) Dataset M1

Analysis	Model	Category	Quantity	%
General	All	Total Questions	17	100.0
General	All	Agreement (3 models)	8	47.06
General	All	Divergence	9	52.94
Distribution	gpt-4o-mini	Screening	2	11.76
Distribution	gpt-4o-mini	Generalist	12	70.59
Distribution	gpt-4o-mini	Specialist	2	11.76
Distribution	gpt-4o-mini	Expert	0	0.00
Distribution	gpt-4o-mini	Error	1	5.88
Distribution	gemini-2.5-flash	Screening	3	17.65
Distribution	gemini-2.5-flash	Generalist	11	64.71
Distribution	gemini-2.5-flash	Specialist	0	0.00
Distribution	gemini-2.5-flash	Expert	0	0.00
Distribution	gemini-2.5-flash	Error	3	17.65
Distribution	sonar-pro	Screening	11	64.71
Distribution	sonar-pro	Generalist	6	35.29
Distribution	sonar-pro	Specialist	0	0.00
Distribution	sonar-pro	Expert	0	0.00
Distribution	sonar-pro	Error	0	0.00

A Tabela 4 apresenta a concordância e distribuição percentual das classificações, conforme os modelos de linguagem: OpenAI: gpt-4o-mini, Google: gemini-2.5-flash e Perplexity: sonar-pro.

Table 4: Agreement and percentage distribution of classifications (Questions 217 to 243) Dataset M2

Analysis	Model	Category	Quantity	%
General	All	Total Questions	27	100.00
General	All	Agreement (3 models)	12	44.44
General	All	Divergence	15	55.56
Distribution	GPT	Screening	0	0.00
Distribution	GPT	Generalist	0	0.00
Distribution	GPT	Specialist	27	100.00
Distribution	GPT	Expert	0	0.00
Distribution	GPT	Error	0	0.00
Distribution	Gemini	Screening	0	0.00
Distribution	Gemini	Generalist	14	51.85
Distribution	Gemini	Specialist	12	44.44
Distribution	Gemini	Expert	0	0.00
Distribution	Gemini	Error	1	3.70
Distribution	Perplexity	Screening	0	0.00
Distribution	Perplexity	Generalist	0	0.00
Distribution	Perplexity	Specialist	27	100.00
Distribution	Perplexity	Expert	0	0.00
Distribution	Perplexity	Error	0	0.00

5.3 Inferência das questões do Dataset M1

Os resultados obtidos indicam um desempenho relativamente próximo entre os três modelos, porém com algumas diferenças relevantes quando analisadas as métricas BLEU e ROUGE-L. O modelo Perplexity apresentou o maior

valor de BLEU (0,0286), sugerindo uma maior sobreposição de n-gramas entre as respostas geradas e o padrão ouro, o que pode indicar maior aderência lexical em termos de escolha de palavras.

Em contrapartida, o modelo GPT obteve o melhor desempenho em ROUGE-L (0,1839), métrica que considera a maior subsequência comum entre os textos, refletindo melhor alinhamento estrutural e semântico das respostas. O modelo Gemini, por sua vez, apresentou os menores valores em ambas as métricas (BLEU = 0,0112, ROUGE-L = 0,1559), indicando menor similaridade global com as respostas de referência.

De forma geral, observa-se que todos os valores de BLEU são baixos, o que é esperado em tarefas de respostas abertas, nas quais diferentes formulações corretas podem ser semanticamente equivalentes, mas lexicalmente distintas. Nesse contexto, a métrica ROUGE-L tende a ser mais informativa, pois captura similaridade estrutural mais ampla. Assim, os resultados sugerem que o GPT apresenta melhor capacidade de gerar respostas semanticamente alinhadas com o padrão ouro, enquanto o Perplexity demonstra maior proximidade lexical pontual. O desempenho inferior do Gemini pode estar relacionado a variações na forma de resposta ou menor aderência ao estilo esperado pelo dataset. Esses achados reforçam a importância de utilizar múltiplas métricas na avaliação de modelos de linguagem em tarefas abertas, especialmente em domínios complexos como o médico.

5.4 Inferência das questões do Dataset M2

Os resultados obtidos a partir da avaliação dos modelos de linguagem — GPT, Gemini e Perplexity — demonstram diferenças relevantes de desempenho no contexto de resolução de questões de múltipla escolha na área médica. As métricas utilizadas para análise foram accuracy (acurácia) e F1-score macro, permitindo uma avaliação tanto da taxa global de acertos quanto do equilíbrio entre precisão e revocação entre as classes.

Observa-se que o modelo Gemini apresentou o melhor desempenho geral, alcançando uma acurácia de 0,9629 e um F1-score macro de 0,9701, indicando não apenas alta taxa de acerto, mas também consistência na classificação entre diferentes alternativas. Esse resultado sugere que o modelo possui maior capacidade de generalização e melhor interpretação semântica das questões e das opções de resposta, o que é particularmente relevante em domínios complexos como o médico.

O modelo GPT também apresentou desempenho elevado, com acurácia de 0,9259 e F1-score macro de 0,9374. Embora ligeiramente inferior ao Gemini, seus resultados indicam robustez e boa capacidade de tomada de decisão em tarefas de múltipla escolha. A pequena diferença em relação ao Gemini pode estar associada a nuances na compreensão contextual ou à forma como o modelo interpreta instruções restritivas (por exemplo, responder apenas com a letra da alternativa).

Por outro lado, o modelo Perplexity apresentou desempenho inferior em comparação aos demais, com acurácia de 0,8148 e F1-score macro de 0,8269. Embora ainda apresente resultados razoáveis, a diferença significativa em relação aos outros modelos pode ser explicada por fatores como maior variabilidade nas respostas, menor aderência ao formato solicitado ou limitações na interpretação das opções em tarefas estruturadas. É possível que o modelo esteja mais otimizado para respostas abertas e baseadas em recuperação de informação (web-grounded), o que pode impactar negativamente seu desempenho em tarefas objetivas e restritas.

A análise conjunta das métricas revela que, embora todos os modelos sejam capazes de resolver questões de múltipla escolha com desempenho satisfatório, há variações importantes na precisão e consistência das respostas. O uso do F1-score macro foi particularmente relevante, pois evidencia o comportamento dos modelos em relação à distribuição das classes, evitando vieses decorrentes de possíveis desbalanceamentos.

Em termos práticos, os resultados indicam que o modelo Gemini se destaca como a melhor opção para aplicações que exigem alta precisão em tarefas de seleção de alternativas, seguido de perto pelo GPT. O modelo Perplexity, embora útil em outros contextos, pode demandar ajustes adicionais de prompt ou pós-processamento para alcançar desempenho comparável nesse tipo de tarefa.

Por fim, destaca-se que os resultados obtidos estão diretamente relacionados ao conjunto de dados utilizado e ao formato do prompt empregado. Estudos futuros podem explorar variações de prompt engineering, aumento do conjunto de dados e avaliação em diferentes domínios para validar a generalização dos resultados observados.

6 Conclusão

Os resultados evidenciam que o desempenho dos modelos varia de acordo com a natureza da tarefa. No Dataset M1 (respostas abertas), o GPT apresentou melhor alinhamento semântico (ROUGE-L), enquanto o Perplexity demonstrou maior aderência lexical (BLEU), e o Gemini teve desempenho inferior em ambas as métricas. Isso reforça que tarefas abertas exigem avaliação baseada em similaridade textual e interpretação semântica, não apenas correspondência exata.

No Dataset M2 (múltipla escolha), o cenário se inverte: o Gemini apresentou o melhor desempenho geral (maior acurácia e F1-score), seguido pelo GPT, enquanto o Perplexity obteve resultados inferiores. Esse comportamento indica maior capacidade do Gemini em tarefas estruturadas e objetivas, nas quais a precisão da escolha é determinante.

De forma geral, conclui-se que não há um modelo universalmente superior, mas sim modelos mais adequados a diferentes tipos de tarefa. O GPT se destaca em geração semântica, o Gemini em classificação estruturada e o Perplexity em proximidade lexical, evidenciando a importância de selecionar o modelo conforme o contexto da aplicação.

REFERENCES

Kassab, J., Massad, C., Kapadia, V., Hajjar, A. H. E., Dahdah, J. E., Helou, M. C. E., Haroun, E., Ramchand, J., and Harb, S. C. (2023). Abstract 16722: Performance evaluation of chatgpt 4.0 on cardiovascular clinical cases from the usmle step 2ck and step 3 of the national board of medical examiners. *Circulation*, 148(Suppl_1):A16722–A16722.

Kung, T. H., Cheatham, M., Medenilla, A., Sillos, C., De Leon, L., Elepaño, C., Madriaga, M., Aggabao, R., Diaz-Candido, G., Maningo, J., and Tseng, V. (2023). Performance of chatgpt on usmle: Potential for ai-assisted medical education using large language models. *PLOS Digital Health*, 2(2):1–12.

Manes, I., Ronn, N., Cohen, D., Ber, R. I., Horowitz-Kugler, Z., and Stanovsky, G. (2024). K-qa: A real-world medical qa benchmark.

Pedrosa, J., Oliveira, D., Meira Jr, W., and Ribeiro, A. (2021). Automated classification of cardiology diagnoses based on textual medical reports. *Journal of Information and Data Management*, 12.

Reading Turchioe, M., Volodarskiy, A., Pathak, J., Wright, D. N., Tcheng, J. E., and Slotwiner, D. (2022). Systematic review of current natural language processing methods and applications in cardiology. *Heart*, 108(12):909–916.

Vishwanath, K., Stryker, J., Alyakin, A., Alber, D., and Oermann, E. (2025). Medmobile: a mobile-sized language model with clinical capabilities. *BMJ Digital Health AI*, 1:e000068.

Wang, Z., Wu, J., Teitge, B., Holodinsky, J., and Drew, S. (2025). Small language models for emergency departments decision support: A benchmark study.

APPENDIX

Gráficos da Classificação do Dataset M1

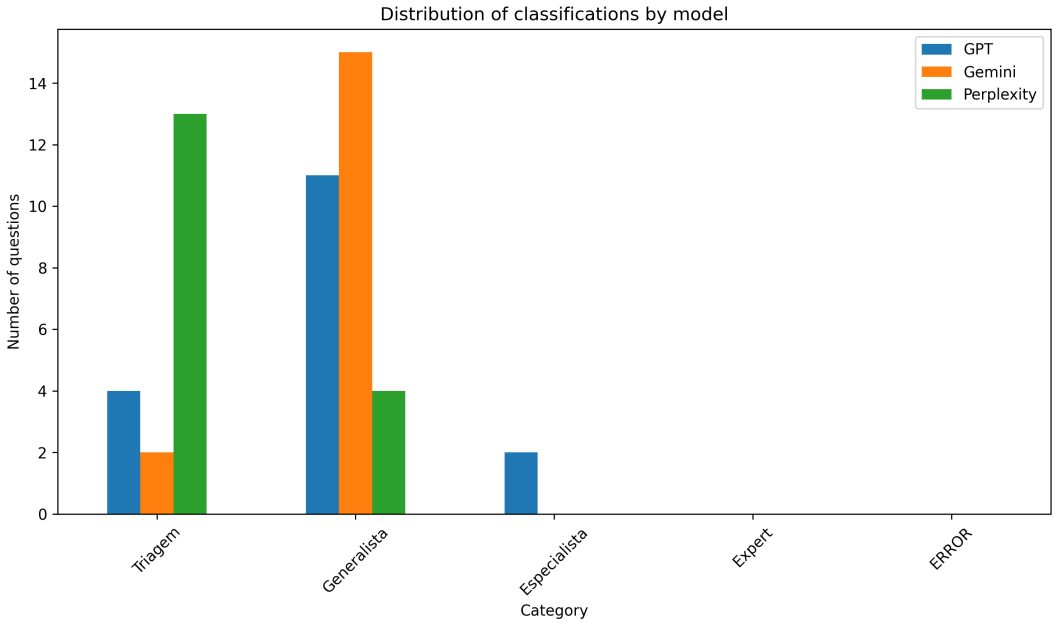

Figure 2: Gráfico Distribuição das Classificações por Modelo - Dataset M1

Gráficos da Classificação do Dataset M2

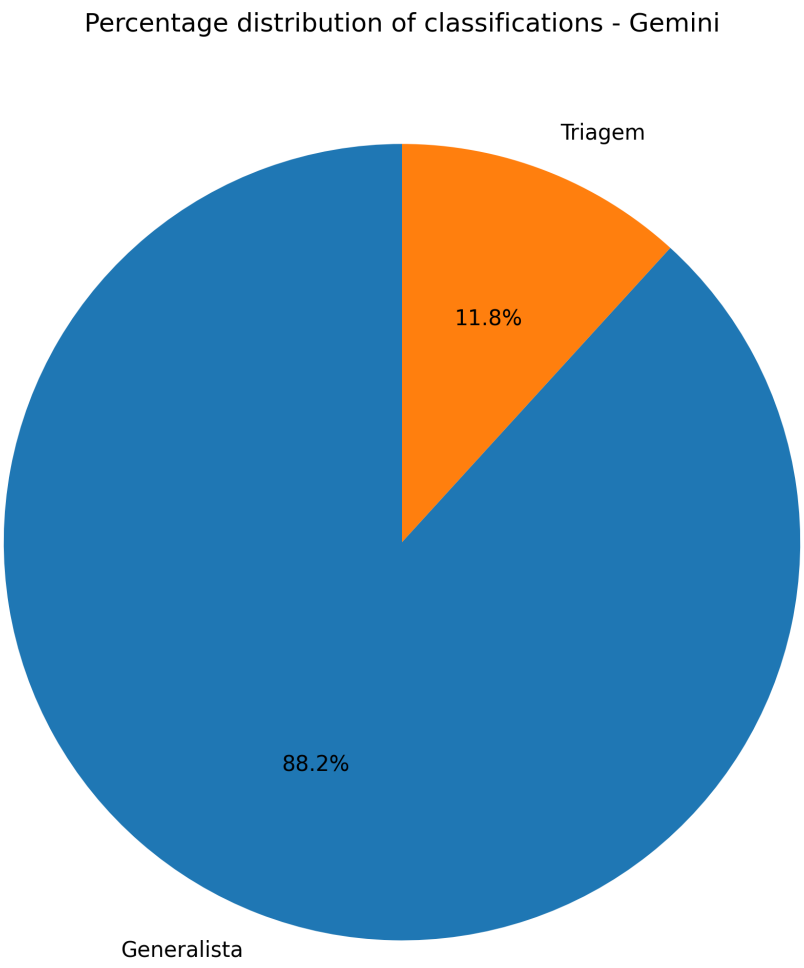

Figure 3: Gráfico Distribuição Percentual das Classificações - Gemini - Dataset M1

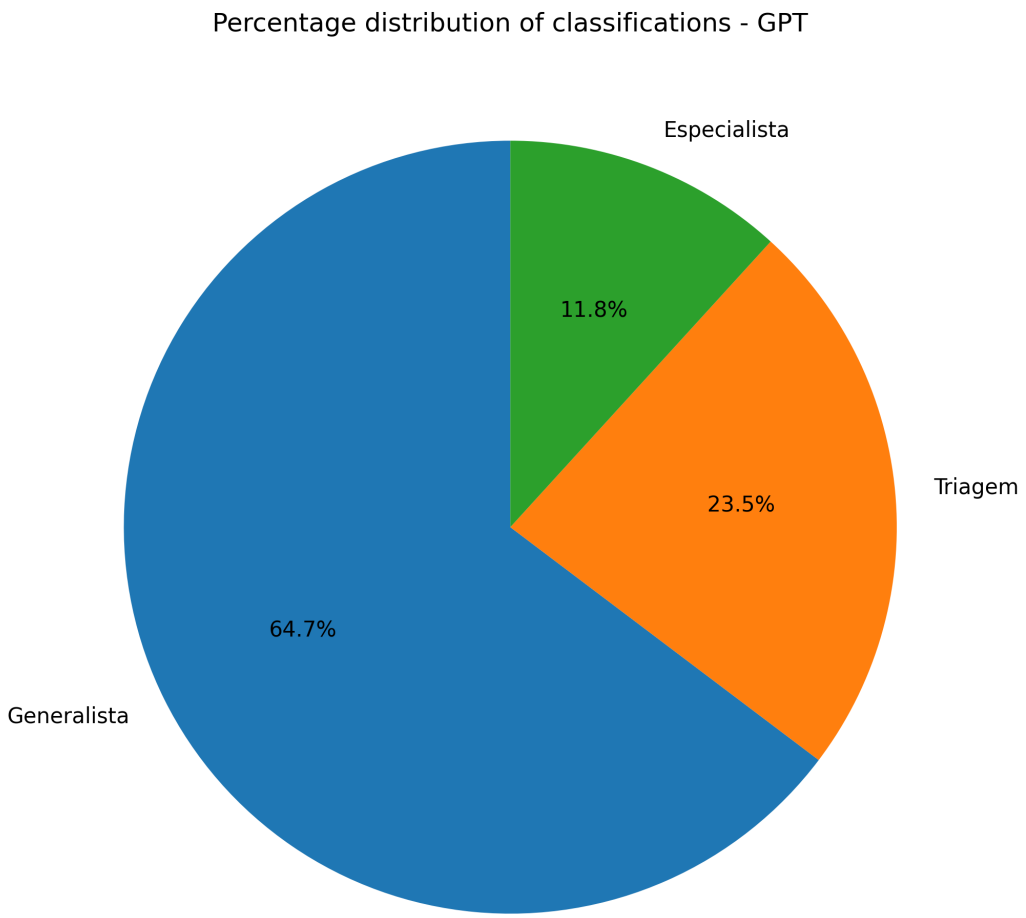

Figure 4: Gráfico Distribuição Percentual das Classificações - GPT - Dataset M1

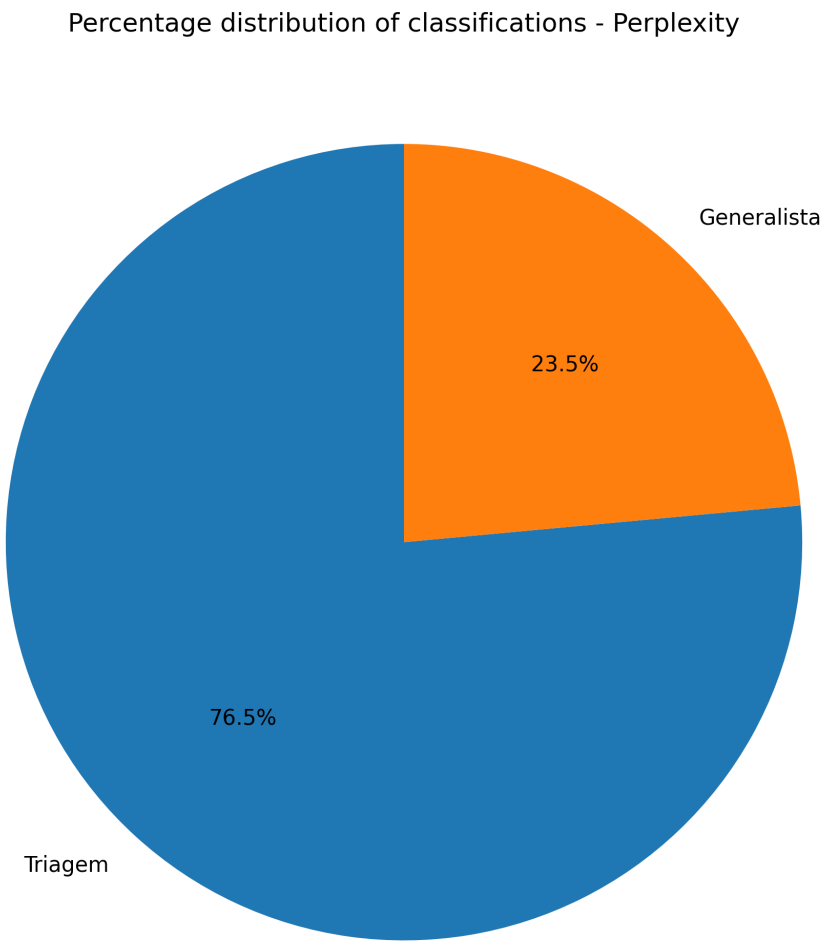

Figure 5: Gráfico Distribuição Percentual das Classificações - Perplexity - Dataset M1

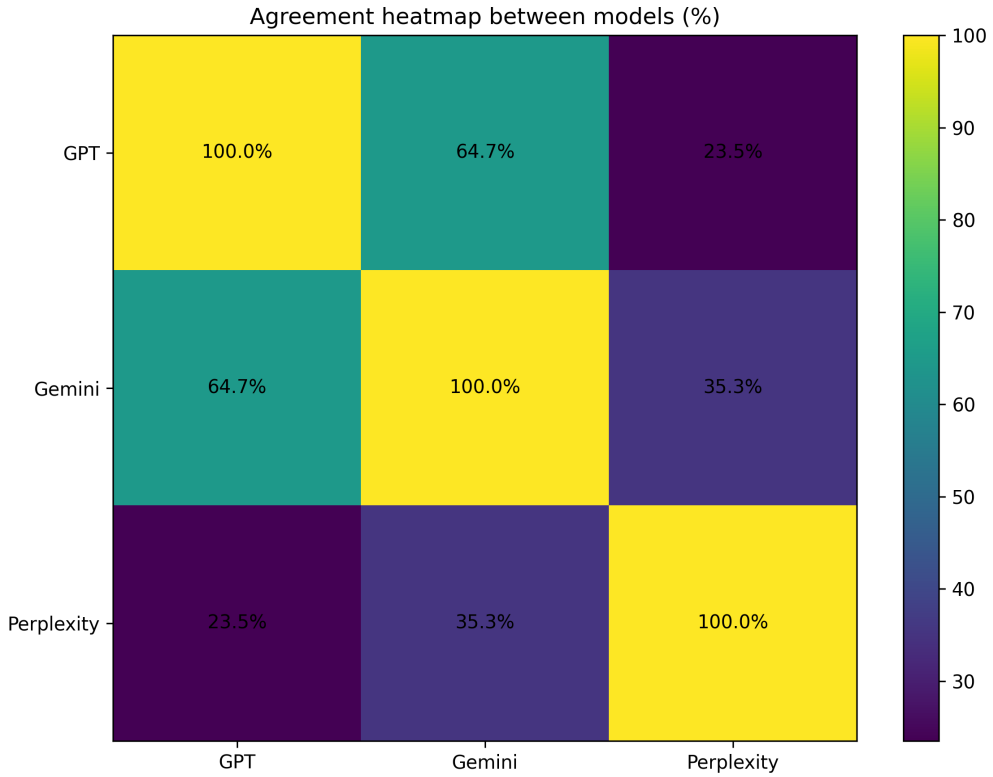

Figure 6: Gráfico Heatmap de Concordância entre Modelos - Dataset M1

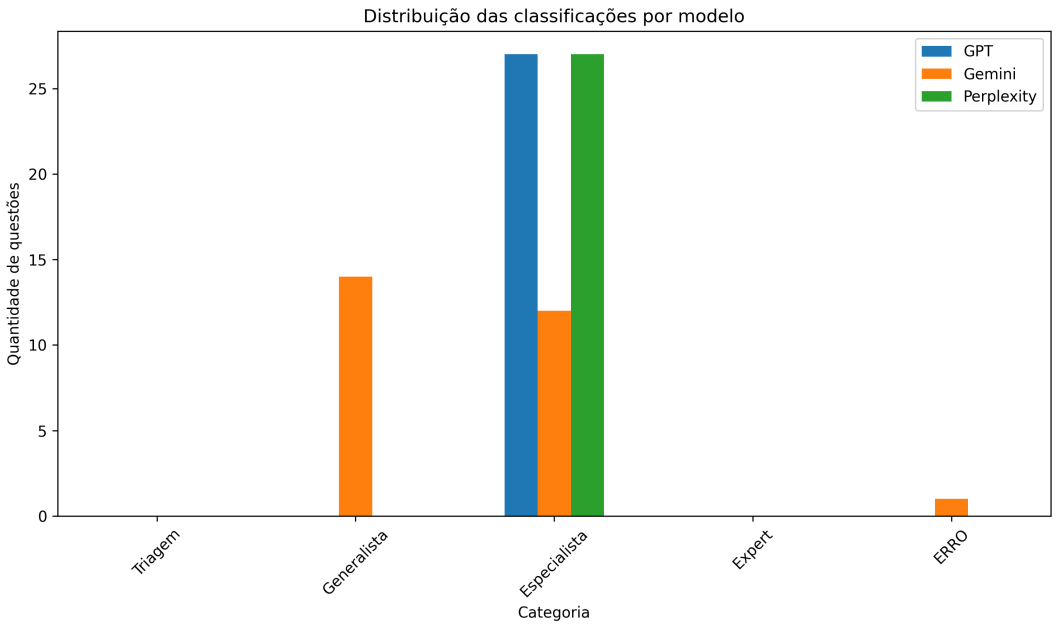

Figure 7: Gráfico Distribuição das Classificações por Modelo - Dataset M2

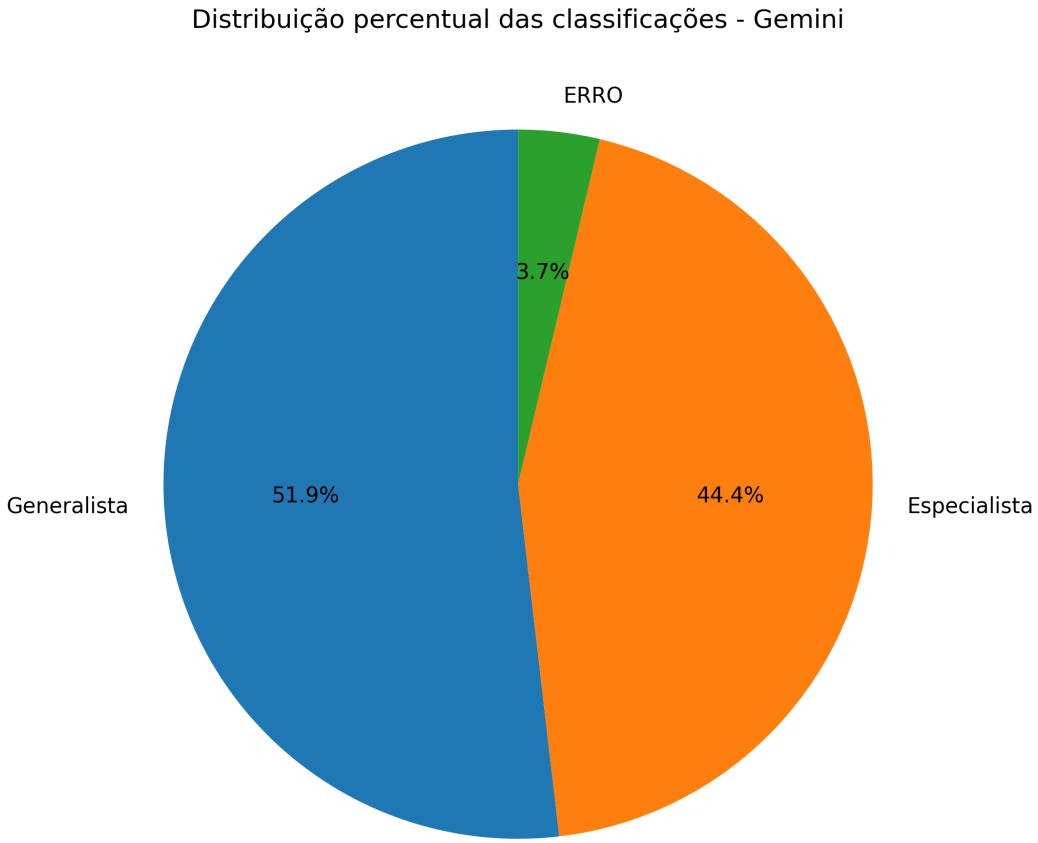

Figure 8: Gráfico Distribuição Percentual das Classificações - Gemini - Dataset M2

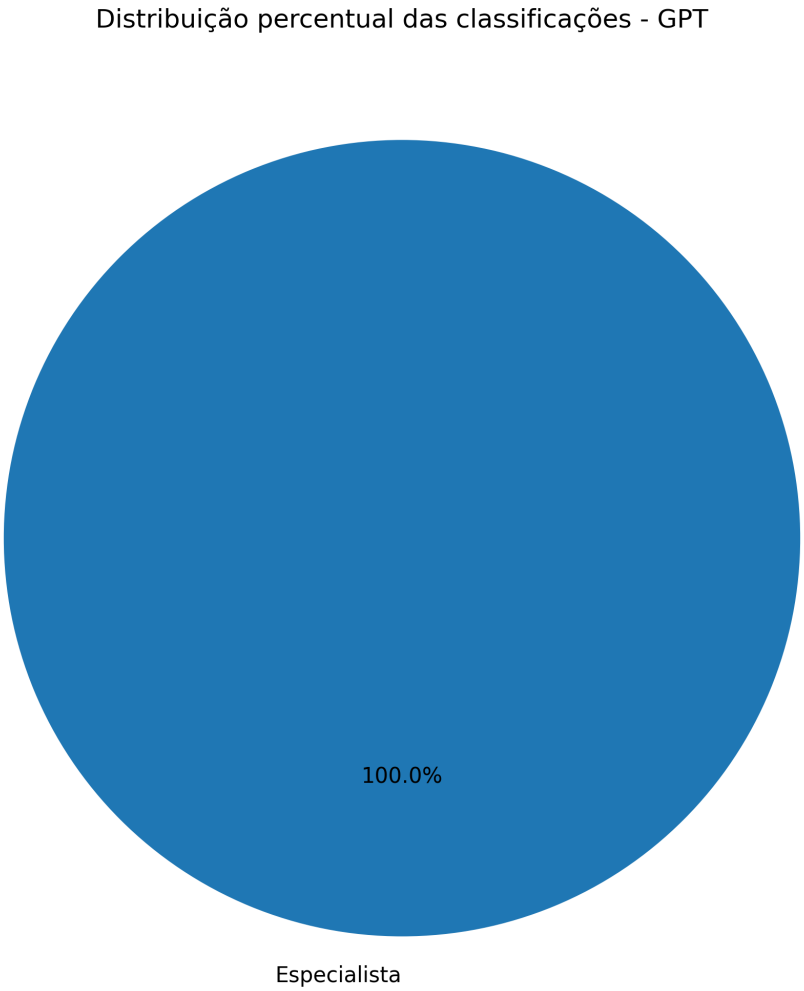

Figure 9: Gráfico Distribuição Percentual das Classificações - GPT - Dataset M2

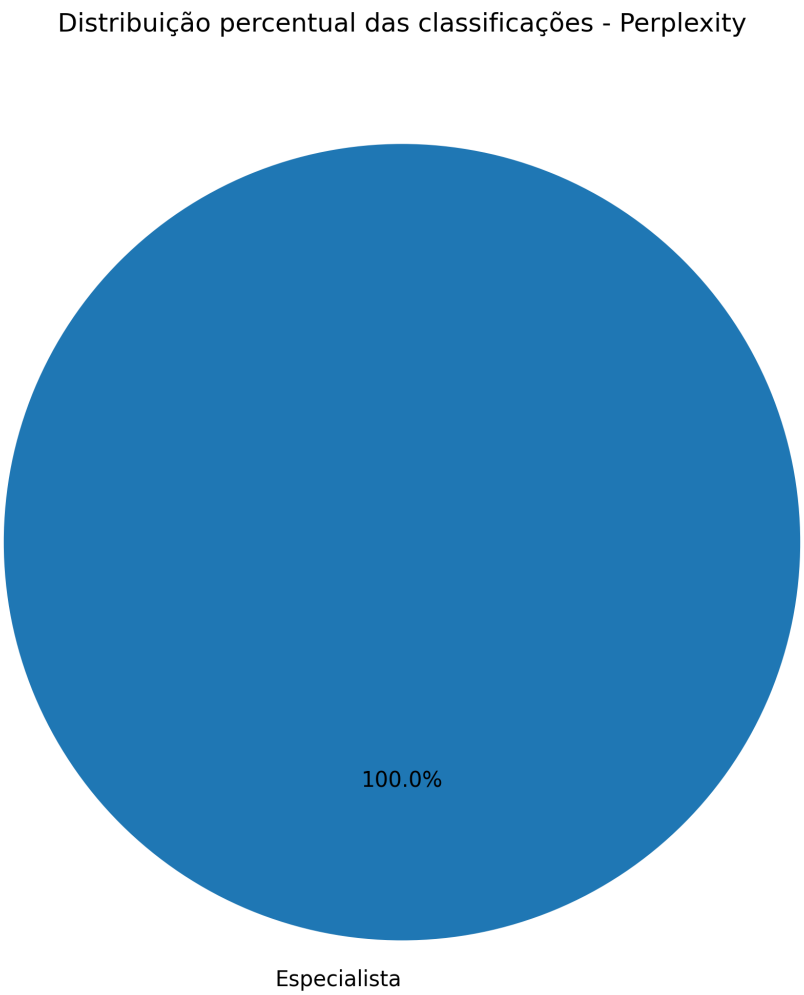

Figure 10: Gráfico Distribuição Percentual das Classificações - Perplexity - Dataset M2

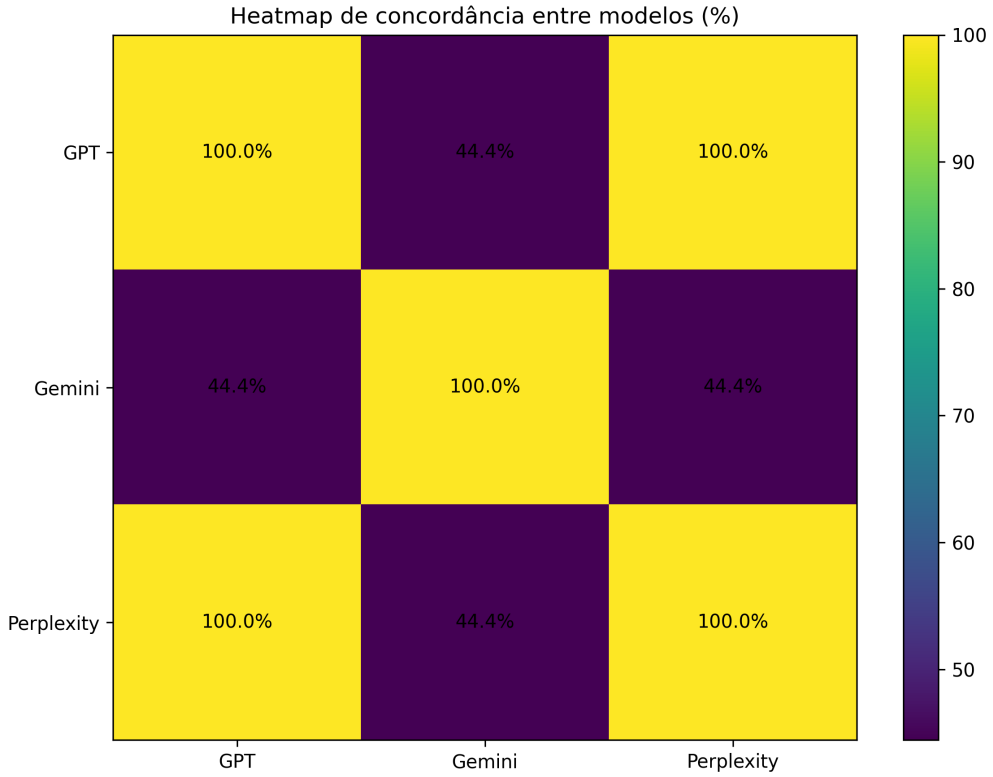

Figure 11: Gráfico Heatmap de Concordância entre Modelos - Dataset M2